ExplAIn Power Power Index

Slide 1

Solo titolo: ExplAIn

come scriverlo:

EXPLAIN

Discorso: Buongiorno, mi chiamo Bianca Perasso, sono una ricercatrice all’interno di MaLGa, Machine Learning Genoa Center, e oggi vi presento **ExplAIn**, un progetto che si occupa di rendere l’intelligenza artificiale **trasparente e comprensibile.**

Slide 2

Titolo: Il contesto

Frase: “Ti fideresti di una decisione che non puoi capire?”

Immagine: una semplice timeline o mappa di domini (tipo sanità, giustizia, cybersecurity) con accanto una percentuale o statistica reale sull'adozione dell'AI in quei settori.

Discorso: I sistemi di AI vengono sempre più spesso utilizzati per prendere decisioni in contesti ad alto impatto, quali la medicina, sicurezza informatica, giustizia. Il problema non è che queste decisioni vengano prese, ma che nella maggior parte dei casi non siamo in grado di ricostruirne il ragionamento. Non è una questione percettiva: è un limite tecnico concreto.

Slide 3

Titolo: Il problema

Immagini: due schemi:

- schema 1: lo schema classico **input → black box → output**
- schema 2: schema **input → box trasparente/di vetro → output**

Discorso: La maggior parte dei modelli attuali opera in questo modo: dato un input, produce un output. Il processo intermedio è opaco. Questo ha conseguenze pratiche: non possiamo verificare su cosa si sta basando il modello, non riusciamo a individuare errori sistematici, e non abbiamo strumenti per valutarne l'affidabilità in contesti critici.

L'explainability non richiede di cambiare l'architettura del modello. Si tratta di aggiungere strumenti di analisi che permettano di osservare e interpretare il suo comportamento dall'esterno, o, in alcuni casi, dall'interno. L'obiettivo è passare da un sistema opaco a uno analizzabile.

Slide 4

Titolo Slide: ExaplAIn

Sottotiolo: “Non basta che funzioni”

Immagine: piramide di rischio del AI Act

Discorso: ExplAIn lavora su questo. Ha l’obiettivo di sviluppare metodi per capire su quali caratteristiche si basa un modello quando produce una previsione, per identificare comportamenti anomali o distorsioni nei dati, e per rendere i risultati leggibili anche a chi non ha una formazione tecnica specifica. L'obiettivo finale è rendere i modelli non solo performanti, ma verificabili. E questo non è solo il risultato di un capriccio: nel 2021 la commissione europea ha proposto l’AI Act per regolare e classificare le applicazioni dell’intelligenza artificiale in base al rischio dei danni causati, mettendo nella categoria high risk tutti quei sistemi utilizzati in contesti sensibili che influenzano la vita delle persone, che includono istruzione, sanità, finanza e privacy. Con l’imminente messa in atto dell’AI Act, presto adottare sistemi di intelligenza artificiali che siano affidabili, robusti, non discriminanti e sicuri non sarà solo giusto, ma sarà legge.

Slide 5

Titolo: Aree di Applicazione

Immagini:

Computer Vision

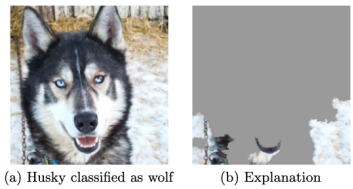

Ribeiro et al.

Malware Detection

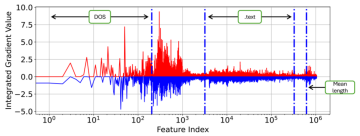

Perasso et al.

Text Translation

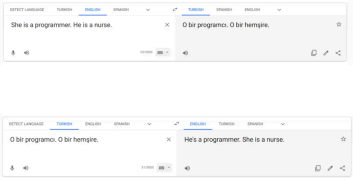

Google Translate

Discorso: Tre esempi concreti su cui agisce L'explainable AI. In computer vision, molti modelli classificano l'immagine non in base all'informazione semantica, ma su informazioni secondarie, come in questo caso lo sfondo. In cybersecurity, modelli per la classificazione di malware che si basano su pattern superficiali, non su comportamenti realmente discriminanti. Infine, per darvi un esempio di quanto questo problema sia concreto, nella foto abbiamo un esempio di come le parole vengano tradotte in base al contesto. In tutti e tre i casi, il problema non è la performance dei modelli, ma il ragionamento che sta dietro alla scatola nera.

ExplAIn non vuole proporre un'alternativa all'intelligenza artificiale, ma ha l'obiettivo di sviluppare strumenti per analizzarla e correggerla. Perché un modello che funziona ma che non sappiamo esaminare rimane, di fatto, uno strumento che non possiamo controllare.